Опис проблема

Циљ овог проблема је креирање једноставног, али ефикасног модела који је у стању да исправља најчешће граматичке грешке у реченицама написаним на енглеском језику.

Скуп података

Grammar Correction

Скуп података се састоји од преко 2000 граматички неисправних реченица на енглеском језику, при чему је за сваку реченицу дата и њена граматички исправна верзија. Реченице садрже различите типове грешака, као што су неправилна употреба глаголских времена, погрешна или изостављена употреба чланова, као и некоректан редослијед ријечи у реченици.

Уколико се током рада покаже да је величина скупа података недовољна за тренирање модела жељеног квалитета, могуће је извршити вјештачко проширење скупа података. Један од приступа је пермутација двије узастопне ријечи у исправним реченицама, чиме се симулира један тип граматичке грешке. Други приступ подразумијева изостављање појединих ријечи, као што су чланови.

Поред овог начина, скуп података је могуће проширити и са потпуно валидним реченицама (гдје није потребна никаква исправка).

Методе за рјешавање проблема

За рјешавање датог проблема користићемо seq2seq приступ с обзиром на то да се ради о трансформацији једног текста у други, граматички исправан текст.

Као модел можемо користити потпуни encoder–decoder трансформер, који је дат у склопу материјала на предмету (*model.py*).

С обзиром да се међу реченицама на улазу налазе и погрешно написане ријечи, није најбоља опција користити токенизатор који издваја токене ријеч-по-ријеч (*CharDelimeterSplit(' ')*), већ је потребно користити Byte-Pair Encoding (издвајање диграма). Овакав токенизатор ћемо моћи искористити и за улаз и излаз, и тренирати на обје колоне скупа података (с обзиром да су све реченице на енглеском језику).

Тренирање би требало спровести у фазама, тако да се модел прво учи на случајевима гдје имамо само једну грешку, а тек касније да убацујемо вјештачки генерисане податке гдје имамо више од једне грешке у реченици.

За брзину учења (learning rate) можемо пробати више метода. Једна опција је да се користи константна бројка, а друга опција би могла бити „Warmup + Cosine decay“ метода.

За функцију губитка (loss function) користићемо Cross-Entropy Loss са label smoothing-ом од 0.1, што спречава прејаку самопоузданост модела.

Користићемо *BLEU* метрику, која говори у којој мјери је излаз нашег модела сличан исправном тексту (преклапање узастопних група токена између излаза и очекиваног текста).

На улаз система ће долазити текстуалне реченице, а у модел (енкодер) токенизоване реченице. Свака реченица се обогаћује специјалним токенима ([SOS] на почетку, [EOS] на крају, и [PAD] за допуну). Непознате ријечи ћемо замјенити специјалним токеном [UNK].

Излаз модела је тензор са вјероватноћама свих токена, које је потребно детокенизовати у читљиви текст. Бирање финалног токена ћемо за почетак радити похлепним (greedy) алгоритмом, а уколико се покаже да не даје добре резултате прећи ћемо на Beam search алгоритам.